

---

# Trabajo Dirigido: Análisis de datos de Baterías para estimación del SOH

César Baeza, Martín Valderrama

---

En este trabajo se desarrolla una metodología de análisis del estado de salud de un set de baterías con una aproximación desde la ingeniería de datos. A partir de descargas aleatorias de la batería, se rescatan características que posteriormente son utilizadas para un análisis por medio de clasificación y de búsqueda por similitud. Teniendo el primer método buenos resultados y el segundo dejando una puerta abierta a mejorar dicha metodología.

El código utilizado para desarrollar este trabajo se encuentra en [https://github.com/MartinVillesca/Analisis\\_Baterias](https://github.com/MartinVillesca/Analisis_Baterias).

## 1 Introducción

Estimar el estado de salud (SOH) de una batería de litio es muy importante para programar mantenencias de equipos, prevenir fallas en equipos o sistemas provocadas por un desgaste de esta. Actualmente existen métodos que se basan en medir la resistencia interna de la batería para así dar un estimado del SOH, sin embargo esto resulta muy costoso y se tienen que realizar en condiciones experimentales.

El objetivo de este trabajo es crear una metodología para estimar el SOH de una batería utilizando los datos que se obtienen en el consumo de una batería. Para esto se utilizarán 2 set de datos<sup>1</sup> de baterías ion litio idénticas, proporcionados por (2), en donde se buscan características que sea representativas y de esta forma entrenar un clasificador basado en Machine Learning y proporcionar un estimado del rango de SOH en el que se encuentra un set de datos reservado para esta prueba.

## 2 Base de datos

La base de datos proporcionada por la NASA contiene múltiples data con diferentes tipos de consumo de batería, entre ellos hay consumos más parecidos al real, donde la carga y descarga de la batería son

---

<sup>1</sup><https://ti.arc.nasa.gov/tech/dash/groups/pcoc/prognostic-data-repository/> el dataset utilizado corresponde al *Randomized Battery Usage Data Set* dataset nro 2.




Figure 1: Perfiles de descarga tanto para le voltaje, corriente y temperatura de los primeros 10 ciclos

aleatorias, por otro se encuentra otro set donde solo la descarga es aleatoria y en cuanto la batería de descarga completamente se vuelve a cargar completamente para luego realizar nuevamente la descarga aleatoria. Este ultimo es el perfil datos utilizados, dado el orden y que resulta más sencillo en análisis de características, como se muestra en la figura 1.

Por otro lado este set de datos resulta muy útil ya que se realiza una descarga a corriente constante (0.04 [A]) cada 50 ciclos y de esta forma se obtiene la capacidad en [Ah] del batería, como se muestra en la figura 2, lo que entrega el estado de salud actual, para ser utilizada posteriormente para estimar el estado de salud de cada ciclo y de esta forma tener etiquetado cada ciclo para un análisis adecuado.

## 3 Antecedentes

La estimación del estado de salud de baterías está muy relacionado a la estimación de la impedancia interna

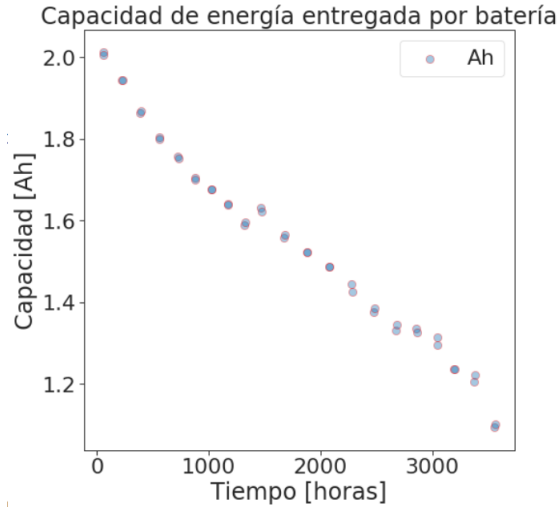


Figure 2: Estado de salud de la batería entregado por la NASA

de la batería. Para modelarla se requieren métodos que implican un barrido de frecuencias en voltaje (1), o una estimación paramétrica del modelo interno de la batería (2).

En el trabajo (1) se desarrolla una metodología para estimar la impedancia interna de la batería a través de la respuesta en frecuencia de la batería y, como esta tiene una estrecha relación con la vida útil de la misma, realizar una estimación del SOH.

En el paper de referencia (2) se realiza una estimación del estado de la impedancia interna de la batería a través de un UKF (Unscented Kalman Filter) para estimar los parámetros del modelo interno de la batería. También se explican los distintos métodos que existen para estimar los parámetros de la batería o el SOH, desde experimentales, físicos, hasta modelos moleculares.

En el paper se desarrolla un modelo dinámico para describir el comportamiento de la dinámica del voltaje en un ciclo controlado de descarga, donde se pretende ajustar la curva del modelo a la real del voltaje, y así estimar el parámetro de impedancia interna de la batería.

## 4 Transformación de la base de datos

Los datos son guardados en el formato .m donde se deben leer formando un diccionario para cada uno de los atributos, donde se van formando las curvas de voltaje, corriente, temperatura y tiempo en que se realiza el muestreo, para finalmente entregar los arreglos

dentro del diccionario.

Luego, los arreglos son descompuestos en cada uno de los saltos que los componen, para realizar un análisis a la dinámica del voltaje de estos datos. Se forma un **DataFrame** de la librería **Pandas** para examinar con mayor facilidad los datos. Luego, se toma cada uno de los saltos y se realiza un análisis de las características del voltaje y temperatura para ingresarlas al modelo de regresión/clasificación.

Los datos disponibles consisten en un **DataFrame** ordenados por salto, donde se especifica el ciclo al que corresponden, las series de tiempo de voltaje, corriente y temperatura. Estos datos son guardados desde el último valor no nulo de corriente anterior al salto actual hasta que se cambie nuevamente a corriente nula.




Figure 3: Estructura del dataset disponible para sacar características. Cada salto corresponde a un color y guarda la información del último instante del salto anterior y de la totalidad del salto actual.

## 5 Captura de características

Dada la estructura presentada en la figura 3, Se establecieron las siguientes características a extraer para cada descarga (escalón de corriente constante) dentro del mismo ciclo (caminata aleatoria completa):

- **Energía total en ciclo (Ene):** Se toma la energía total consumida en dicha descarga, para luego sumarla a las descargar posteriores en el mismo ciclo, de esta forma se tiene cuenta energía ha entregado la batería hasta dicho ciclo. Si se define  $E_{j-1}$  como la energía hasta la descarga anterior (excepto para la primera descarga donde la energía anterior es cero), donde  $j \in [0, m]$  con  $m$  como el numero de descarga;  $V_i$  y  $I_i$  como el voltaje y corriente del dato  $i$ -ésimo dentro de la misma descarga, con  $i \in [0, n]$  donde  $n$  corresponde al total de datos en la descarga. Entonces se tiene que la expresión general para la energía de cada descarga es la presentada en la ecuación 1.

$$E_j = E_{j-1} + \sum_i^n V_{ji} I_{ji} \quad (1)$$

- **Magnitud Corriente (Mg):** Corresponde a la corriente  $I_0$  de cada descarga.
- **Mediana Corriente (Med):** Corresponde al valor medio de cada descarga  $I_0/2$ .
- **Magnitud Relativa ( $Mg_{rel}$ ):** Corresponde a la diferencia entre la magnitud de corriente de la descarga anterior y la actual en el mismo ciclo (excepto para la primera descarga), como se muestra en la ecuación 2.

$$Mg_{rel} = Mg_{i-1} - Mg_i \quad (2)$$

- **Media Magnitud Relativa ( $Med_{rel}$ ):** Corresponde a la mediana de la magnitud relativa  $Mg_{rel}/2$ .
- **Magnitud Relativa Absoluta ( $Mg_{rel\_abs}$ ):** Corresponde a la norma de la magnitud relativa.
- **Media Relativa Absoluta ( $Med_{rel\_abs}$ ):** Corresponde a la norma de la mediana relativa.
- **Temperatura inicial ( $T_{ini}$ ):** Corresponde a la temperatura en que se encuentra la batería al inicio de la descarga  $T_0$ .
- **Diferencia de temperatura ( $\Delta T$ ):** Corresponde a la diferencia de temperatura inicial y la final en

una misma descarga, ponderada por la magnitud de corriente, como se muestra en la ecuación 3, en donde  $j \in [0, m]$  con  $m$  como el numero de descargar e  $i \in [0, n]$  donde  $n$  corresponde al total de datos en la descarga.

$$\Delta T_j = |(T_{j,i=0} - T_{j,i=n}) / Mg_j| \quad (3)$$

- **Media primera derivada promedio ( $V'$ ):** Corresponde al promedio de la derivada discreta entre valores de voltaje de la misma descarga, como se presenta en la ecuación 4, donde  $j \in [0, m]$  con  $m$  como el numero de descargar e  $i \in [0, n]$  donde  $n$  corresponde al total de datos en la descarga. Además la diferencia de tiempo entre la toma de datos corresponde a 10 [s].

$$V'_j = mean \sum_{i=0}^{n-1} \frac{V_{i+1} - V_i}{10} \quad (4)$$

Esta característica se puede interpretar como la pendiente promedio de cada descarga, la en principio puede variar a medida que se deteriora la batería.

- **Mediana segunda derivada promedio ( $V''$ ):** Es el promedio de la segunda derivada discreta entre valores de voltaje de la misma descarga, como se presenta en la ecuación 5, donde  $j \in [0, m]$  con  $m$  como el numero de descargar e  $i \in [0, n]$  donde  $n$  corresponde al total de datos en la descarga.

$$V''_j = mean \sum_{i=0}^{n-2} \frac{V'_{i+1} - V'_i}{100} \quad (5)$$

Esta característica se puede interpretar como la concavidad promedio del voltaje en una misma descarga.

- **Estimación de constante de tiempo de circuito RC (RC):** Como se muestra en la figura 4, cuando existe una caída de corriente en la descarga, se ve un efecto capacitivo en el voltaje. Teniendo esto, se hace una búsqueda en los datos y se verifica donde el efecto capacitivo se termina, es decir el voltaje comienza a descender, como se muestra en la figura 4, donde la parte se muestra en rojo hasta que punto de la descarga sucede este fenómeno.




Figure 4: Representación de data seleccionada en el primer ciclo.

Teniendo esto se tiene el tiempo en que se produce, se puede calcular un estimado como se muestra en la ecuación 6, donde  $t_0$  corresponde al instante de tiempo donde comienza la descarga y  $t_k$  corresponde al tiempo donde termina el fenómeno. Además 0.632 corresponde al factor de corrección que permite calcular el  $\tau$  que a su vez corresponde a al valor que se busca en un circuito RC básico.

$$RC_j = (t_0 - t_j) \cdot 0.632 \quad (6)$$

Cabe destacar que este fenómeno no sucede en todas las descargas, por lo que el resto de datos se fijan como  $RC = 0$ .

- Primera derivada RC ( $RC'$ ): De la misma manera que en la primera derivada del voltaje, se tiene la primera derivada promedio de las descargas en donde sucede el fenómeno RC, hasta en que se pierde este efecto.

- Segunda derivada RC ( $RC''$ ): Al igual que en la segunda derivada del voltaje, se tiene la segunda derivada promedio de las descargas en donde sucede el fenómeno RC, hasta en que se pierde este efecto.

Tanto en la primera como segunda derivada RC, en las descargas donde este fenómeno no sucede por defecto se fijan como cero.

- Potencia instantánea (P): Corresponde a la potencia entregada por la batería en cada descarga, en los primero 10 instantes de tiempo, como se representa en la ecuación 7, donde  $j \in [0, m]$  con  $m$  como el numero de descargar e  $i \in [0, n]$  donde  $n$  corresponde al total de datos en la descarga.

$$P_j = \sum_{i=0}^{10} V_i I_i \quad (7)$$

- Diferencia de voltaje con salto anterior ( $\Delta V_1$ ): En esta característica se trata de capturar la tendencia de la baja de voltaje durante el consumo de la batería. Se toma el voltaje del último salto, donde la corriente es aún distinta de cero, y se resta del voltaje del primer instante donde la corriente nuevamente es distinta de cero.
- Diferencia de voltaje con instante anterior al salto ( $\Delta V_2$ ): En este caso se tiene un caso semejante al anterior, pero el primer valor del voltaje que se tiene es el del instante inmediatamente anterior al salto de corriente. Se trata de capturar la respuesta resistiva de la batería, al ser la diferencia de voltaje en dos instantes consecutivos con una tasa de muestreo de 1s.

## 6 Modelo de clasificación/regresión

Con el fin de analizar la calidad de las características seleccionadas y cual de estas representan de mejor forma el estado de salud de la batería, se plantea un estudio basado en Aprendizaje de Máquinas utilizando el clasificador Random Forest. Para esto primero hay que preparar el set de datos con las características extraídas anteriormente.

Se divide la cantidad total de ciclos en  $n$ -clases y a cada descarga se le asigna una etiqueta. Por ejemplo: Si se toma como 100% el primer ciclo y 0% el último ciclo y se desean  $n\_clases = 5$ , entonces la asignación de la etiqueta ocurre como se muestran en la tabla 1.

Este valor puede cambiar dependiendo si se desea más sensibilidad a coste de menos precisión.

Table 1: Representación de label

%	Clase
[100,80]	1
[80,60]	2
[60,40]	3
[40,20]	4
[20,0]	5

Dado que se está trabajando con 2 sets de datos de distintas baterías con exactamente las mismas especificaciones, ambos sets se concatenan para generar un único set de datos, eliminando los columnas correspondientes a arreglos de voltaje, corriente, tiempo y temperatura. Anteriormente se comprobó el comportamiento de las variables de las baterías, y para cada una se presentaba un comportamiento similar. De esta forma el nuevo set de datos esta conformado únicamente por características y el label a cual corresponde cada descarga.

Posteriormente se Deben eliminar los valores conflictivos, ya que en la extracción de características existen valores que no están definidos (NaN) o son infinitos, por lo que se deben eliminar.

Como los datos no tienen el mismo eje de referencia estos se deben escalar, normalizando de acuerdo al valor más grande, desde este punto los datos se encetaran listos para ser estudiados. Se aplica un escalamiento de acuerdo a los mínimos y máximos

## 6.a) Algoritmo

Para tener una mejor comprensión de cómo se desarrolla el análisis de sensibilidad, se explicará de forma general el procedimiento del algoritmo utilizado.

Teniendo los datos listos para ser procesados, lo primero que se realiza es separar los datos en conjunto de entrenamiento y validación. Para esto existe un parámetro que se llama **Win**, el cual corresponde al tamaño de ventana para tomar datos consecutivos como se muestra en la figura 5, en donde se realiza **pop** a todas la filas desde una fila *random i* hasta el label *i+Win*, con lo que al final se tiene un conjunto de ventana de datos extraídos de forma aleatoria. De esta forma se van guardando ventanas de datos con la misma etiqueta. Este paso de extracción de datos se repite hasta que el conjunto de validación represente el 30% del conjunto total.




Figure 5: Representación de ventana para extracción de datos.

Como aún los datos de entrenamiento se encuentran ordenados, ahora es posible mezclarlos para evitar sobre ajuste. Luego entrena el clasificador Random Forest. Teniendo entrenado el clasificador se procede a estimar cada etiqueta del conjunto de validación de manera separada. Sin embargo, como estos datos fueron extraídos por ventanas, todos los datos de la misma ventana deben pertenecer a la misma clase, por lo que para mejorar el desempeño del clasificador se calcula la moda de dicha ventana, cambiando la predicción de cada etiqueta al valor obtenido en la moda. En caso de haber 2 o mas clases con la misma frecuencia, la etiqueta cambia a la clase menor, como se muestra en al figura 6.




Figure 6: Representación de aplicación de la moda en venta de datos.

Lo anterior correspondería a tomar una ventana de tiempo mirando a la batería para extraer características, las que luego serán entregadas como batch al modelo, y el SOH final será el más frecuente en el modelo.

## 6.b) Análisis de sensibilidad

Para realizar el estudio de los datos se procede a fijar parámetros para comenzar a evaluar otros y de esta forma hacer un análisis de sensibilidad. Los parámetros a modificar son los siguientes:

- Energía = Varía de 500 a 10000 [J]
- Numero de características: se varía de 1 a 15
- Tamaño de ventana: Varía de 1 a 30
- Numero de clases (n\_clases): Son 3,5,8,10

Primero se realiza un búsqueda por cada rango donde el clasificador tiene buen desempeño, para tener el punto de partida y comenzar a variar los parámetros, de esta forma encontrar los mejores valores. Los valores iniciales son los presentados en la figura 2

Table 2: Valores iniciales de parámetros.

Parámetro	Valor inicial
Energía	1500
N características	9
Tamaño ventana	12
N de clases	5

Se comienza con el análisis de sensibilidad del tamaño de la ventana, con esto se fija el numero de clases y se varía el tamaño de ventana desde 1 a 20, esto se repite 10 veces y se calcula su desviación.

El criterio para seleccionar el mejor parámetro es de acuerdo al accuracy alcanzado. En caso de haber 2 opciones se elige la de menor varianza. El resultado del tamaño de ventana se puede ver en la tabla 3. También se puede ver el análisis completo en la sección 9.b).

Table 3: Mejores parámetros de tamaño de ventana (Win) para cada numero de clases.

N Clases	Tamaño Ventana
3	11
5	10
8	14
10	6

Tomando le mejor parámetro para cada N de clase, se modifica la energía donde todos los datos con energía mayor o igual se descartan. Esto es un parámetro importante a variar, los datos en donde la batería se encuentra casi descargada (ha entregado más energía) son los más difusos y difíciles de clasificar. Los resultados del análisis se pueden ver en 4. Si se desea ver los resultados completos estos se encuentran en la sección 9.c).

Table 4: Mejores parámetros de corte de energía para cada numero de clases.

N Clases	Tamaño Ventana	Energía[J]
3	11	3500
5	10	2500
8	14	1500
10	6	1000

Posterior al análisis de energía, es necesario saber la cantidad de características que entregan un mejor desempeño en el clasificador. Esto se consigue utilizando la función "SelectKBest" con función "Mutual\_info\_classif" para discriminar, donde la función se define como:

$$I(X;Y) = D_{KL}(P_{X,Y}||P_X \otimes P_Y)$$

Donde  $D_{KL}$  corresponde a la divergencia Kullback-Leibler, donde la divergencia Q dado P es :

$$D_{KL}(P||Q) = \sum_{x \in \mathcal{X}} P(x) \log\left(\frac{P(x)}{Q(x)}\right)$$

Definido lo anterior, el mejor resultado para cada clase es la presentada en la tabla 5 y cuyo resultado en detalle se puede ver en la sección 9.d). El significado de la función de información mutua, da una medida de la dependencia entre dos entidades, siendo 0 si es que no existe dependencia y 1 si la dependencia es alta.

hyperref

Table 5: Mejores parámetros de número de características para cada numero de clases. Los resultados también son expuestos como matriz de confusión junto a los anexos

N Clases	Ventana	Energía[J]	N Características
3	11	3500	8
5	10	2500	10
8	14	1500	6
10	16	1000	6

A pesar de lo resultados mostrados anteriormente se puede ver en la tablas de sensibilidad (9.d)) donde

desde 6 características el resultado no varía mucho, esto se debe a que el coeficiente de información mutua para más de 6 características es muy similar. Es por lo anterior que solo se toman las 6 características con coeficiente más alto.

Table 6: Mejores 7 características utilizadas y sus respectivos mutual info scores.

Característica	Mutal info score
Energía	0.9629
T <sub>ini</sub>	0.6222
V'	0.6906
V''	0.5338
$\Delta V_1$	0.6784
$\Delta V_2$	0.8624

Utilizando la mejor configuración para cada número de clases se obtienen los resultados presentados en la tabla 7, donde se observa la precisión antes y después del post-procesamiento utilizando el valor con mayor frecuencia.

Table 7: Resultados con mejores parámetros, para cada número de clases.

N Clases	Accu-pre [%]	Accu-post[%]
3	91.13	97.58
5	91.46	96.12
8	80.4	93.46
10	70.20	85.10

## 7 Modelo basado en la similitud

En esta sección se especifica el modelo de búsqueda de por similitud del SOH. En breve, se trata de un modelo que en base a las características que se tienen del test, es decir, del conjunto de saltos de corriente seleccionados, se compara con el conjunto de entrenamiento en un espacio euclidiano. Se buscan los vectores más cercanos en el espacio de características, y se genera una distribución de los valores de SOH encontrados, de este modo, se genera una distribución de los valores posibles del SOH del conjunto de test.

El modelo creado se basa en la misma metodología anterior de encontrar las características del dataset, se realiza un filtro por el estado de carga de la batería entre 100 y 5000. Luego, como existe una tendencia entre las características debido a la magnitud del salto realizado, se comparan vectores cuya magnitud de salto sea la misma.

Además, en el modelo se recolectan los  $n$  vecinos más cercanos al vector de prueba. Como se tiene un conjunto de vectores de prueba ( $m$ ) se tendrán  $m \times$

$n$  vectores semejantes a los vectores de prueba, con los que se puede generar un histograma del SOH de ellos para mostrar la distribución resultante del SOH estimado.




Figure 7: C

La distancia utilizada para generar este modelo es la distancia euclidiana. Se ignoran las características que no se encuentran en el vector de test. Lo anterior nos limita al análisis de clusters que se encuentran en un espacio linealmente separable. Para realizar un análisis más acabado, se debería realizar un análisis con funciones de kernel que puedan separar el espacio en un espacio en que sean linealmente separables, y ahí realizar el análisis.

Además, se realiza un análisis de componentes principales, para así reducir la dimensionalidad de la data y para descartar características de poca importancia. Sobre este nuevo espacio se realiza la búsqueda por similitud. Estos resultados del método son insatisfactorios debido a que no se encuentra una distribución de SOH con un valor que destaque y sea coincidente con el valor real del SOH de test. Los malos resultados del método pueden recaer en la métrica utilizada para computar la similitud.

Otros resultados también fueron obtenidos con KernelPCA de la librería `sklearn`, donde se utiliza un kernel de funciones de base radial para encontrar un nuevo espacio. Pero los resultados fueron también insatisfactorios.



## 8 Conclusión

Durante este trabajo se realizó el manejo de datos, transformación de los mismos, extracción de características y posterior análisis, con distintos resultados. El objetivo de encontrar una metodología para trabajar este tipo de datasets y generar un modelo que sea capaz de estimar un estado de salud de la batería, se logró. Sin embargo, los resultados de los modelos no fueron los esperados.

En el modelo de clasificación/regresión desarrollado se obtienen buenos resultados, sin embargo, estos dependen de la cantidad de clases que se quieran o, lo que es lo mismo, la cantidad de particiones que se quieran del SOH. Esto limita la precisión del modelo. Por otro lado, al obtener estos resultados, se tiene ya una metodología donde se puede iterar cambiando parámetros del modelo o las características extraídas para un mejor resultado.

Referente a los resultados obtenidos con el modelo de clasificación/regresión, se puede observar (en 9.a)) que las predicciones hechas por el modelo se concentran en la diagonal, lo que indicaría que el resultado predicho está muy cercano al real, y no se clasifica erróneamente con una clase muy lejana. Lo anterior da pie para seguir mejorando el modelo extrayendo nuevas características y/o mejorando el clasificador/regresor.

Algo similar ocurre con el modelo de búsqueda de similitud, pero en este caso, se debe desarrollar mejor la idea detrás de este, y así la estructura de comparación de los vectores de características. Como propuesta de este modelo se deja la mejora de las características entregadas y la métrica utilizada para comparar, ya que al usar distancia euclidiana se puede incurrir en el error de ignorar elementos que pueden estar cercanos en geometrías especiales. Esto puede suceder con características que se relacionan de forma no lineal a lo largo de los ciclos.

Como trabajo futuro, se recomienda explorar a fondo las características entregadas al modelo y la relación que tienen estas con la degradación de la batería. Además de generar un modelo de regresión que entregue con un nivel de precisión la estimación del SOH, a modo de distribución de probabilidad. Se pudo ver en el trabajo realizado, que este acercamiento a la estimación del estado de salud de una batería a partir de las características, es factible.

## 9 Anexo

### 9.a) Resultados de Clasificador/Regresor

Matrices de confusión para clasificador/regresor con parámetros óptimos para cada separación de SOH.

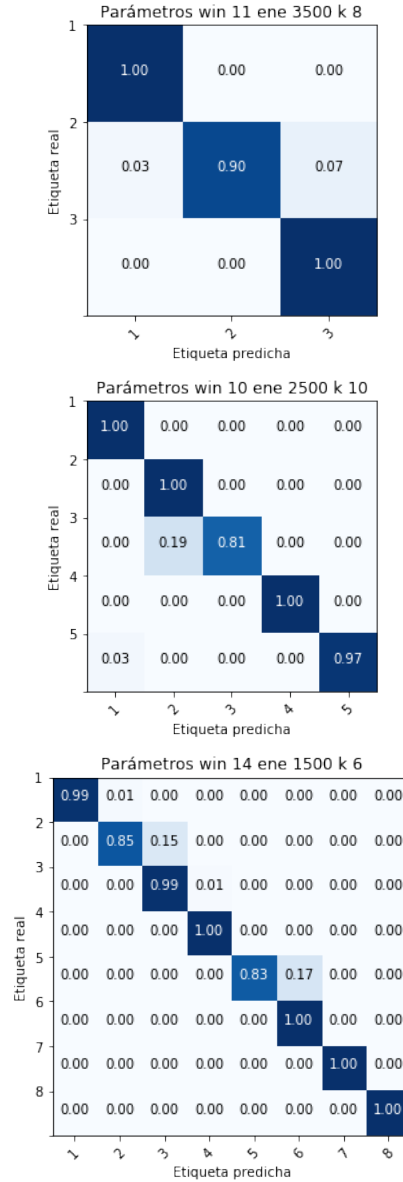


Figure 8: 3, 5 y 8 separaciones del SOH, respectivamente






Figure 9: 10 separaciones del SOH

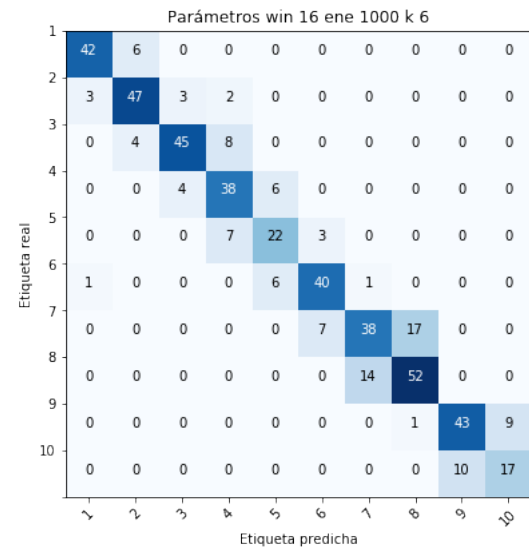


Figure 11: 10 separaciones del SOH sin promediar

Esta última muestra cómo es el resultado antes de que se realice tome la moda por ventana de test.




Figure 10: 10 separaciones del SOH sin promediar

Esta matriz muestra la cantidad de descargas de test de cada clase y su clasificación.

## 9.b) Tamaño de ventana

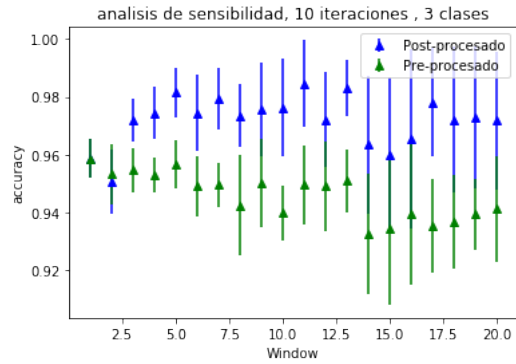


Figure 12: Análisis de sensibilidad en tamaño de ventana para 3 clases




Figure 13: Análisis de sensibilidad en tamaño de ventana para 5 clases

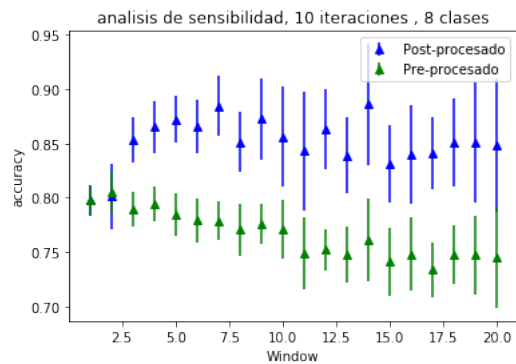


Figure 14: Análisis de sensibilidad en tamaño de ventana para 8 clases




Figure 15: Análisis de sensibilidad en tamaño de ventana para 10 clases

## 9.c) Corte de energía




Figure 16: Análisis de sensibilidad de corte de energía para 3 clases




Figure 17: Análisis de sensibilidad de corte de energía para 5 clases

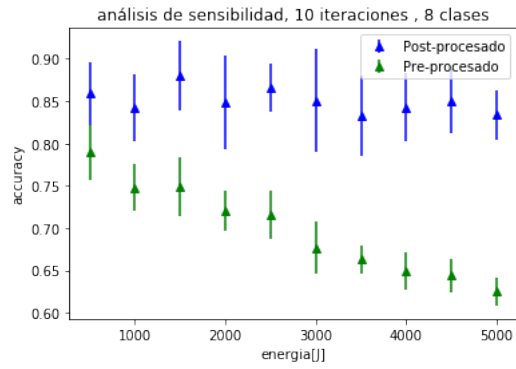


Figure 18: Análisis de sensibilidad de corte de energía para 8 clases




Figure 21: Análisis de sensibilidad de numero de características para 5 clases

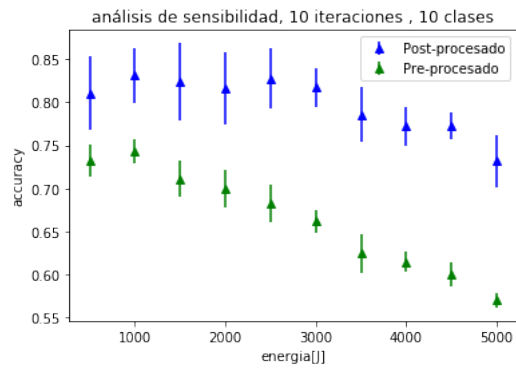


Figure 19: Análisis de sensibilidad de corte de energía para 10 clases




Figure 22: Análisis de sensibilidad de numero de características para 8 clases

#### 9.d) Numero de características




Figure 20: Análisis de sensibilidad de numero de características para 3 clases




Figure 23: Análisis de sensibilidad de numero de características para 10 clases

## References

- [1] Benavides, M. **Determinación de indicadores de estado de salud de baterías de ion-litio, mediante el uso de espectroscopía de impedancia electroquímica y caracterización del término de la vida útil basado en la generación de calor dada por la impedancia interna**, *Tesis para optar al grado de Magíster*, U. de Chile, 2018
- [2] Bole, B.; Kulkarni, C.; Daigle, M. **Adaptation of an Electrochemistry-based Li-Ion Battery Model to Account for Deterioration Observed Under Randomized Use**, 2015